

Université Paris Saclay

Compte-Rendu Stage

Licence Double Diplôme Mathématiques-Informatique - 2024

Théorie des graphes : algorithmes
d'approximation combinatoire

Superviseur de stage : Monika Csikos

Co-superviseur : Daniel Vaz

présenté par

Corentin De Rette

Contexte du stage

J'effectue mon stage de 3^{ème} année de licence double diplôme Mathématiques-Informatique, du 15/05/2024 au 31/07/2024 au sein de l'IRIF.

L'IRIF (Institut de Recherche en Informatique Fondamentale) est une unité mixte de recherche entre le CNRS et l'Université Paris Cité créée en 2016. Il est situé dans le 13^{ème} arrondissement de Paris et comporte une centaine de membres permanents.

Comme indiqué sur la page de présentation de l'IRIF¹ : « Les recherches menées à l'IRIF reposent sur l'étude et la compréhension des fondements de toute l'informatique [...] l'IRIF est reconnu pour ses contributions portant sur la conception et l'analyse d'algorithmes, l'étude des modèles de calculs et de représentation des données, les fondements des langages de programmation, le développement logiciel, la vérification et la certification. »

Mon stage se déroule dans l'équipe « Théorie et algorithmique des graphes » du pôle « Algorithmes et structures discrètes », dirigé par Valia Mitsou.

Ma responsable de stage est Monika Csikos, maître.sse de conférence à l'université Paris-Cité. Son travail de recherche porte principalement sur la théorie des graphes, et en particulier les graphes géométriques et algorithmes d'approximation.

J'ai contacté Monika Csikos car son champ d'étude porte sur la théorie des graphes, domaine que j'ai découvert durant ma licence dans les cours d'algorithmique et d'informatique théorique. Je souhaitais approfondir ce domaine lors de mon stage. Au premier jour du stage, Monika Csikos m'a proposé différents sujets en rapport avec la théorie des graphes et les algorithmes d'approximation. J'ai choisi le sujet « correlation clustering » car il est le plus proche des notions et problèmes abordés pendant ma formation de licence.


Je suis également supervisé par Daniel Vaz, post-doctorant à l'université Paris-Dauphine. Ses sujets de recherches principaux sont les algorithmes d'approximation, la théorie des graphes, et la complexité.

Les recherches de l'IRIF se déroulant dans un cadre international, beaucoup de ses membres ne sont pas francophones. C'est notamment le cas de Monika Csikos et Daniel Vaz. L'intégralité des échanges se déroule donc en anglais.

¹ <https://www.irif.fr/informations/presentation>

Problématique

Le problème de *correlation clustering* est le suivant : étant donné un graphe complet valué aux arêtes par + ou -, comment trouver une partition des sommets en clusters qui minimise le nombre d'arêtes transgressées, c'est à dire le nombre d'arêtes - au sein d'un même cluster et d'arêtes + entre différents.



Ce problème a été introduit en 2004, ainsi que la preuve de sa NP-complétude. De nombreux algorithmes d'approximation ont été proposés depuis. Certains ont un facteur d'approximation démontrés. Pour d'autres, leur efficacité a été constatée expérimentalement mais reste à démontrer.

Pour un problème de minimisation, comme celui de *correlation clustering*, un algorithme de facteur d'approximation k donne une solution de coût attendu $Calg$ qui est inférieur ou égal à k fois le coût de la solution optimale $Copt$:

$$Calg \leq k Copt$$

La plupart des algorithmes ayant un facteur d'approximation démontré, dont le meilleur est de 1.76, utilisent de la programmation linéaire, ce qui implique une grande complexité temporelle.

Quant aux algorithmes n'utilisant pas la programmation linéaire, celui ayant le meilleur facteur d'approximation, qui est de 3, est l'algorithme « du pivot ».

L'objectif du stage est d'évaluer les algorithmes d'approximation n'utilisant pas la programmation linéaire, de les tester, et si possible de prouver leur facteur d'approximation.

Résumé du travail effectué

Semaine 1 : état de l'art

La première semaine de mon stage a été consacrée à l'analyse de la littérature sur le domaine. Monika Csikos m'a proposé l'étude des principaux articles sur le problème de « correlation clustering », notamment :

- *Correlation Clustering*² (2004) : définit le problème de « correlation clustering » et présente un algorithme d'approximation de facteur 4.
- *Aggregating Inconsistent Information: Ranking and Clustering*³ (2008) : présente l'algorithme « du pivot », dont le facteur d'approximation est 3.
- *An Efficient Local Search Algorithm for Correlation Clustering on Large Graphs*⁴ (2023) : présente des résultats expérimentaux sur différents algorithmes d'approximation, montrant leur efficacité et leur temps d'exécution sur des graphes larges.

Semaines 2-4 : programmation et analyse expérimentale

Durant les 3 semaines suivantes j'ai programmé les outils nécessaires à l'analyse de performance des 4 algorithmes : « pivot », « pivot ordonné », « pivot ordonné en version alternative » et « vote ». Monika Csikos m'a présenté les algorithmes. Elle m'a laissé choisir le langage de programmation. La disponibilité des bibliothèques PYTHON (NumPy) et plus précisément concernant les algorithmes de graphes et d'optimisation linéaire (NetworkX et PuLP), a orienté mon choix vers ce langage.

Les outils développés sont :

- programmes implémentant les algorithmes
- générateur de graphes, notamment avec NetworkX
- outil d'exécution des algorithmes sur un grand nombre de graphes
- outil pour analyse statistique des résultats

² Nihikil Bansal, Avrim Blum & Shuchi Chawla

³ Nir Ailon, Moses Charikar & Alantha Newman

⁴ Nathan Cordner & George Kollios

- outil de calcul de l'optimum basé sur la programmation linéaire (bibliothèque PuLP)

Lorsque j'ai rencontré des problèmes de programmation, j'ai consulté la documentation des différentes bibliothèques, ainsi que le forum de développement « stackoverflow ». J'ai résolu les problèmes d'algorithmique en m'appuyant sur le support de mes référents de stage ainsi que les cours en ligne de sites académiques.

Ma démarche d'analyse expérimentale a consisté à :

- 1/ générer des fichiers contenant un grand nombre de graphes (1 000 graphes de 100 noeuds)
- 2/ faire tourner chaque algorithme sur le fichier de graphes. Le résultat à analyser est le coût d'exécution.
- 3/ analyser les résultats, en utilisant l'outil d'analyse de données

J'ai ainsi réalisé des tests sur plusieurs dizaines de milliers de graphes. Les temps de traitement pouvaient dépasser 10h sur mon ordinateur portable.

En synthèse, mes résultats expérimentaux corroborent l'hypothèse d'un algorithme du « pivot ordonné » plus efficace de +8% à + 65%, que celui du pivot classique (cf résultats en Annexes et GitHub : https://github.com/Corent123/correlation_clustering_algos).

Semaines 5-6 : étude du facteur d'approximation

Suite aux résultats expérimentaux concluants, nous avons décidé d'étudier le facteur d'approximation des différents algorithmes. Mon travail s'est partagé entre la lecture d'articles démontrant les facteurs d'approximation afin de comprendre les méthodes utilisées, et la participation aux réunions de travail de mes référents de stage afin d'analyser les différents algorithmes.

Les démonstrations utilisent principalement des arguments probabilistes et de programmation linéaire.

Par ailleurs, j'ai pu assister à une conférence donnée par Venkatesan Guruswami « *When and why do efficient algorithms exist (for constraint satisfaction and beyond) ?* » qui présentait une nouvelle manière de prouver la NP-complétude pour les problèmes de satisfaction de contraintes.

Conclusion

En conclusion, les résultats expérimentaux obtenus sont satisfaisants car ils montrent une meilleure performance des nouveaux algorithmes par rapport à celui du pivot.

Cependant, les travaux d'analyse progressent mais ne sont pas conclusifs à ce jour - 30 juin 2024. Pendant le prochain mois de mon stage, une des options prévues est de modifier les algorithmes afin de faciliter leur analyse.

Ce stage m'a permis de découvrir le monde et les méthodes de la recherche en informatique dans un contexte international et anglophone. J'ai eu l'opportunité d'assister à une conférence riche sur le domaine de l'algorithmique.

J'ai bénéficié d'une grande autonomie lors de mon stage. J'étais notamment libre de proposer et de choisir les langages, librairies et architectures de programmation, beaucoup plus que durant les projets réalisés en licence. Ceci m'a appris à travailler de manière plus autonome. J'ai progressé en programmation, notamment sur l'utilisation de nouvelles bibliothèques Python.


Sur le plan théorique, j'ai découvert de nouvelles manières d'utiliser les outils mathématiques vus durant la licence, par exemple en Probabilités et Optimisation linéaire. En particulier, j'ai constaté l'intérêt de la programmation linéaire dans les démonstrations d'informatique théorique.

Je tiens à remercier chaleureusement mes superviseurs de stage, Monika Csikos et Daniel Vaz, pour leur accueil et leur accompagnement.

ANNEXES

Tableau de résultats expérimentaux coût moyen des algorithmes, comparé à celui du pivot

Probabilité d'une arête +	Pivot ordonné	Pivot semi ordonné	Vote
0,05	0,79	0,79	0,78
0,1	0,76	0,76	0,75
0,2	0,77	0,77	0,76
0,3	0,81	0,81	0,79
0,4	0,87	0,87	0,84
0,5	0,92	0,92	0,9
0,55	0,91	0,91	0,91
0,6	0,85	0,85	0,88
0,7	0,67	0,67	0,7
0,8	0,53	0,53	0,54
0,9	0,43	0,43	0,43
0,95	0,39	0,39	0,39



Chaque point correspond à des tests réalisés sur 1 000 graphes aléatoires de 100 noeuds.

exemple de lecture de la 1ere ligne :

sur 1 000 graphes de 100 noeuds, dont la probabilité qu'une arête soit + est de 0,05

le coût de l'algorithme Pivot ordonné est en moyenne 0,79 fois celui de l'algorithme du Pivot